Lecture 3 [45]

> Considering a neural network with D input neurons, a single ReLU hidden layer with H units and softmax output layer with K units, write down the formulas of the gradient of all the MLP parameters (two weight matrices and two bias vectors), assuming input x, target t and negative log likelihood loss. [10]

Označme z jako vstup do poslední vrstvy a g jako zlatou distribuci, poté $\frac{\partial L}{\partial z} = \boldsymbol{o} - \boldsymbol{g}$. Zbytek z chain rule, stačí si rozkreslit síť do jednotlivých vrcholů.

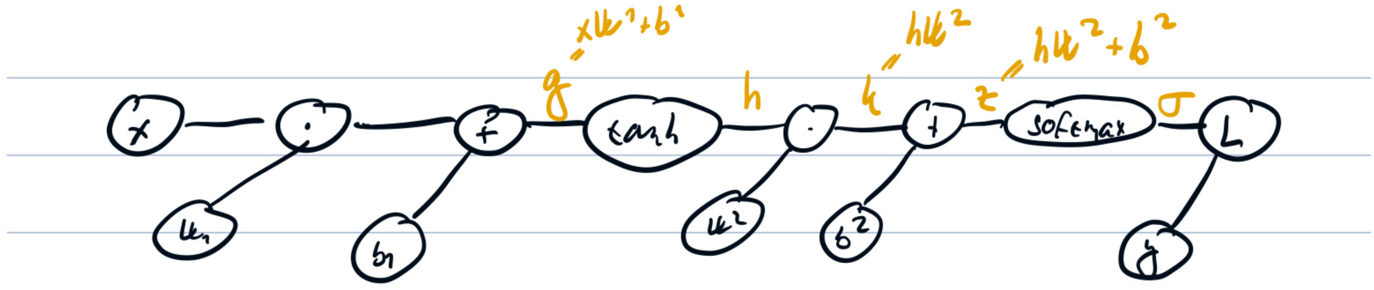

ZAJÍMÁ NÁS

$$\frac{\partial L}{\partial b_1} = \frac{\partial L}{\partial z} \cdot \frac{\partial z}{\partial h} \cdot \frac{\partial h}{\partial h} \cdot \frac{\partial h}{\partial g} \cdot \frac{\partial g}{\partial b^1} = (o - 1_g) \cdot 1 \cdot w^2 \cdot (1 - h^2) \cdot$$

$$\frac{\partial L}{\partial w_1} = \frac{\partial L}{}$$

$$\frac{\partial L}{\partial b_2} = \frac{\partial L}{\partial z} \cdot \frac{\partial z}{\partial b^2} = \frac{\partial L}{\partial o} \cdot \frac{\partial o}{\partial z} \cdot \frac{\partial z}{\partial b^2} = o - 1_g$$

$$\frac{\partial L}{\partial w^2} = \frac{\partial L}{\partial z} \cdot \frac{\partial z}{\partial w^2} = h \cdot (o - 1_g)$$

> Assume a network with MSE loss generated a single output $o \in \mathbb{R}$, and the target output is g. What is the value of the loss function itself, and what is the gradient of the loss function with respect to o? [5]

Hodnota loss je $(o-g)^2$, gradient je prostě derivace přechozího výrazu, tedy $2(o-g)$.

> Assume a network with cross-entropy loss generated a single output $z \in \mathbb{R}$, which is passed through the sigmoid output activation function, producing $o = \sigma(z)$ If the target output is g, what is the value of the loss function itself, and what is the gradient of the loss function with respect to z? [5]

Hodnota loss je $-\sum g_i \log \boldsymbol{o}_i$. Gradient se těžko počítá vůči o, ale vůči z je roven $o - g$.

> Assume a network with cross-entropy loss generated a k-element output $z \in \mathbb{R}^K$, which is passed through the softmax output activation function, producing $o = softmax(z)$. If the target distribution is g, what is the value of the loss function itself, and what is the gradient of the loss function with respect to z? [5]

Hodnota loss je $-\sum g_i \log \boldsymbol{o}_i$. Gradient se těžko počítá vůči o, ale vůči z je roven $\boldsymbol{o} - \boldsymbol{g}$.

> Define L2 regularization and describe its effect both on the value of the loss function and on the value of the loss function gradient. [5]

Regularizace je obecně cokoli, co má za cíl snížit generalizační chybu. L2 regularizace zmenšuje váhy,

$$\tilde{J}(\boldsymbol{\theta}; \mathbb{X}) = J(\boldsymbol{\theta}; \mathbb{X}) + \lambda \|\boldsymbol{\theta}\|_2^2, \quad (1)$$

což se poté projeví v gradientu jako

$$\boldsymbol{\theta}_i \leftarrow \boldsymbol{\theta}_i - \alpha \frac{\partial J}{\partial \boldsymbol{\theta}_i} - 2\alpha\lambda\boldsymbol{\theta}_i \quad (2)$$

> Describe the dropout method and write down exactly how is it used during training and during inference. [5]

Chceme, aby naše neurony (resp. jejich váhy) byly dobré a nezávislé na ostatních, proto při trénování s pností p neuron vyřadíme (tj nastavíme mu hodnotu 0).

Při inferenci k dropoutu nedochází, a protože máme najednou více neuronů než jsme měli při trénování, naškálujeme všechny jejich výstupy $(1-p)$ krát. Případně můžeme naopak při tréninku naškálovat výstupy neuronů nahoru, $1/(1-p)$ krát.

> Describe how label smoothing works for cross-entropy loss, both for sigmoid and softmax activations. [5]

Někdy dochází k overfittingu, protože se MLE snaží dotáhnout poslední procentíčko v nějaké 99,99% predikci — taková predikce nám ale běžně stačí. Proto jako gold distribuci nebereme one-hot, ale $(1-\alpha) \cdot \mathbf{1}_{gold} + \alpha \cdot 1/(\#\ \text{classes})$.

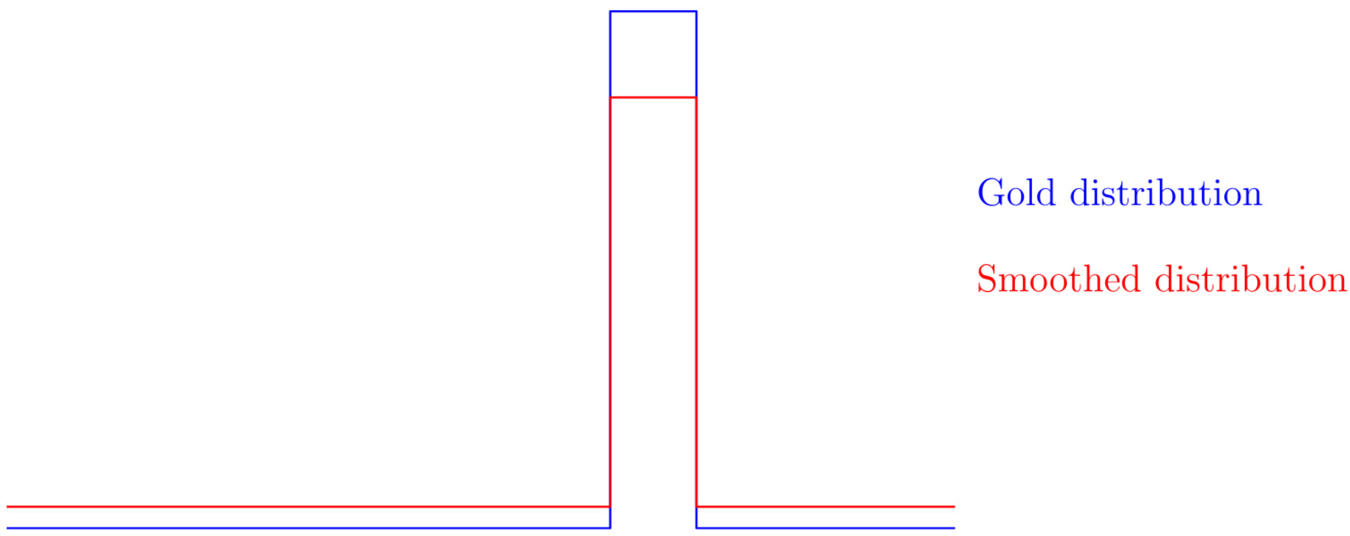

> How are weights and biases initialized using the default Glorot initialization? [5]

Biasy na 0, matice $\mathbb{R}^{m \times n}$ z distribuce $U\left[-\sqrt{\frac{6}{m+n}}, \sqrt{\frac{6}{m+n}}\right]$.

Váhy nemohou být všechny 0, protože by se všechny trénovaly stejně — proto je inicializujeme náhodně. Tyto konkrétní hodnoty volíme proto, aby rozptyl vygenerovaných matic byl $1/n$, což poté pomůže zachovat stabilní rozptyl napříč skrytými vrstvami. Ten chceme proto, že pokud by se rozptyl měnil, například rostl, rostly by nám i hodnoty aktivací a gradienty.